AW

LOCAL-FIRST COMPANION

AGI.Wind
功能与使用说明书

给鱼丸和你的本地陪伴指南

适用对象：本机主人（网页端 / QQ 私聊 / 已允许的 QQ 群）

版本：2026-10-27 本地版 · 文档编号：AW-MANUAL-01

一句话：所有核心数据留在本机；你可以通过网页或 QQ 与鱼丸聊天、听她说话、让她记事、主动找你，也可以随时停下来。

目录

1. 先看这里：一分钟认识她
2. 启动、打开与停止
3. 网页界面地图
4. 日常聊天
5. QQ 使用
6. 人格与记忆
7. 语音与实时通话
8. 图片、表情包与 Agent 工具
9. 主动消息与独处思考
10. 模型、设置与外观
11. 归档、备份、隐私与安全
12. 常见问题与排查
13. 当前边界

1. 先看这里：一分钟认识她

> AGI.Wind 是一个本地优先的 AI 陪伴服务。前端是浏览器里的聊天客户端，后端是本机 Gateway；聊天记录、人格档案和记忆主要保存在本机 PostgreSQL 里。鱼丸是当前陪伴角色。

可以聊天

文字流式回复、按行分段的气泡、图片、语音、表情包；QQ 私聊也能用。

可以记住

人格档案、主人记忆、群成员记忆分开保存；记忆可查看来源、隐藏、纠正。

可以说话

本地 Breeze 克隆音色；语音消息与实时通话；QQ 语音消息会转写成文字再进入对话。

可以主动找你

长时间没聊天，或回复后你没有继续，她可以独处思考，再决定要不要主动开口。

最重要的一点：她不是"假装回复"的脚本。没有配置对话模型时，聊天的真实结果是明确报错，不会伪造回答；语音、图片、QQ 也各有清晰的失败提示。

2. 启动、打开与停止

2.1 正常启动

在项目根目录双击 `启动本地服务.cmd`，或者打开 PowerShell 执行：

```
cd C:\Users\wind\Desktop\AGI.Wind
.\scripts\start-local.ps1
```

默认只监听本机；如果想让同一局域网里的其他设备访问，使用 `启动服务端(局域网).cmd` 或 `.\scripts\start-local.ps1 -BindHost 0.0.0.0`。

2.2 打开客户端

浏览器打开 **http://127.0.0.1:18440/**。本机回环访问会自动登录，不需要手动输入访问令牌。状态页是 **http://127.0.0.1:18440/status**。

2.3 查看状态与停止

双击 `查看本地状态.cmd` 查看各依赖是否运行；双击 `停止本地服务.cmd` 正常停止（会保留数据）。如果只想重启 Gateway，可先停止再启动，数据库默认保留。

2.4 她依赖的本地服务

服务	默认地址	作用
Gateway	127.0.0.1:18440	网页、API、聊天生成和大部分业务逻辑
PostgreSQL	127.0.0.1:55432	对话、人格、记忆、任务等数据
记忆服务 / worker	127.0.0.1:8141	本地语义检索与后台记忆提炼
ASR	127.0.0.1:8139	实时通话的语音识别
TTS（Breeze）	127.0.0.1:8137	本地语音合成；当前音色 yuwan
SnowLuma	127.0.0.1:5099	QQ 接入端（外部进程，需自己登录 QQ）

> 语音、ASR、QQ 都是增强能力：它们没起来时，文字聊天仍然可以使用；对应页面会给出状态或错误，不会把失败伪装成成功。

3. 网页界面地图

左侧栏分三组，常用入口都在这里：

分组	页面	做什么
陪伴	对话	和鱼丸的当前聊天；发文字、图片、语音；查看运行日志
陪伴	对话归档	查看旧对话；恢复为当前对话或永久删除
陪伴	QQ 群	已接入的群窗口；群聊只读浏览，每个群可单独启停
她的档案	灵魂档案	她的名字、人设、背景、你的称呼、双方头像
她的档案	记忆	查看、筛选、纠正、隐藏/恢复记忆；运行提炼与维护
她的档案	表情包	上传、改名、打标签、隐藏/恢复、删除表情包
系统	模型与语音	配置对话/识图/语音等模型；调语音概率、试听
系统	Agent 能力	开关工具、联网检索、文件/命令访问、审批和预算
系统	用量统计	查看 token、语音等使用情况和限额
系统	连接	服务器地址、客户端密钥、QQ 私聊/群聊设置、服务状态
系统	外观与账户	浅色/深色/跟随系统、退出会话、关于

右上角可以切换主题；聊天页右上角有日志按钮和「⋯」对话菜单。聊天窗口永远只有一个“当前对话”，旧对话会进入归档，不会同时开很多个上下文互相串线。

4. 日常聊天

4.1 发送与停止

在底部输入框输入文字，按 **Enter** 发送，**Shift+Enter** 换行。生成过程中可以点停止按钮；点「…」里的归档会开始一段新对话，旧对话变只读。

4.2 分段与语音

- 模型决定怎么分段：通常一行一个气泡，不再机械地按标点拆。
- 输入框旁有「语音」开关。关闭时按概率（默认约 30%）随机带语音；打开后每条有正文的回复都尝试带语音。语音是独立气泡，可播放/暂停。
- 隐藏的情绪标记会从文字中剥离，用来决定语气；它不会出现在聊天正文里。

4.3 图片与表情包

输入框左下角「＋」选择图片，或 Ctrl+V 粘贴，最多 4 张，可纯图片发送。图片会先经过识图，再生成回复。表情包可以在「表情包」页管理；她需要时会自己挑，不建议每轮都强制发表情。

4.4 运行日志

点聊天页右上角日志按钮，打开「她的活动」：

- 默认只显示本次打开后的新活动，每次回复或独处思考折叠成一张卡片；
- 点开卡片可以看到"她在想什么、翻了什么记忆、做了什么动作"；
- 工具名会翻译成人话（翻记忆、上网查、挑表情包等）；HTTP/事件 ID/内部技术字段默认隐藏；
- 右上角「看原始日志」可切回完整终端视图，便于排查问题；错误和警告会保留并展开。

5. QQ 使用

5.1 接入前提

QQ 聊天由外部的 SnowLuma 接入端负责登录和 OneBot v11 协议，AGI.Wind 不保存 QQ 密码。打开 **http://127.0.0.1:5099** 完成 SnowLuma 的 EULA 和 QQ 登录，然后在网页「连接 → QQ · 与鱼丸私聊」里填写：

- 主人 QQ 号、鱼丸 QQ 号；
- 反向 WebSocket 地址（同机通常是 `ws://127.0.0.1:18440/api/v1/integrations/qq/ws`）；
- 至少 32 位连接令牌，并复制到 SnowLuma 的 Access Token；
- 把绑定对话选为网页当前对话。

> **只响应主人**：QQ 私聊固定只认绑定的主人 QQ；群聊必须逐群填写并启用，不会因为"在群里说过话"就获得主人权限。

5.2 私聊：等你把话说完

鱼丸不会在你第一句话刚落下时立刻抢答。私聊连续发来的几句话会先进入 **消息防抖**：

- 默认：你停下后等 **2.2 秒**；看起来说完了，再等 **0.9 秒**确认；最多等你 **8 秒**。
- 如果句尾是逗号/顿号/"然后、还有、因为……"等，说明没说完，她会继续等；最多到硬上限。
- 最多合并 **8 条 / 4000 字**；这些碎片会变成一个回合，只触发一次思考。
- 图片、语音、命令会先结束当前文字批次，避免顺序颠倒。
- 等待期间不占用生成 worker；发「停止」会取消还没提交的批次。

参数可在「连接 → QQ」里调整：**说完后等待、最多等到、最终确认等待、每段基础等待、两条最少间隔、每轮最多几段**。

> **当前边界**：防抖目前只对主人私聊的纯文字生效；群聊仍按原逻辑逐条处理，以免打乱群消息顺序和接话判断。

5.3 发送节奏

她回复时不会一口气把 8 条消息甩出来。每段之前会按文本长度做对数曲线等待，并加一点随机抖动；默认基础等待 1 秒、两条最少间隔 1.8 秒、单段最长 8 秒、每轮最多 8 段。你原来的基础值 0.6 秒会保留，但已经叠加了曲线和最小间隔，所以会比以前明显慢。

觉得太快，可在 QQ 设置里把「每段基础等待」调到 1.2–1.5 秒；觉得太慢可调回 0.8 秒左右。设为 0 会关闭等待，仅建议调试使用。

5.4 群聊

- 群聊默认关闭，只接入「允许的群号」列表中的群；每个群一个独立窗口。
- 接话模式：「智能接话」在她刚回复过的短窗口内判断明确追问；「仅 @ / 引用」只响应 @她或引用她消息。
- 其他群消息仍会作为上下文观察和成员记忆来源，但在未触发回复时不调用对话模型。
- 群内成员使用独立成员记忆，不会写进主人私密记忆池；匿名消息不会提炼成员记忆。
- 连接页的群窗口列表可以逐群启停；关闭后该群消息不再触发回复和成员记忆。

在 QQ 里发 **/stop** 或 **停止** 可以停止当前回答和待发送内容；主人私聊与群聊共用这个入口。

6. 人格与记忆

6.1 灵魂档案

「灵魂档案」决定她是谁：名字、身份、性格、说话方式、背景、与你的关系、你的称呼等。它也包含双方头像：她的头像和"你的头像"分开设置，选图后可拖动/缩放裁剪，保存档案后生效。

- 档案有版本号；保存时如果旧格式长文本会重复进入上下文，页面会提醒。
- 修改人格或记忆后，正在进行的生成可能被取消，避免用旧人格继续回答。

6.2 记忆页

「记忆」页不是只读摆设：

- **列表与搜索**：按正文或来源原文搜索；按类型、状态、时间筛选；显示重要度、来源数、访问次数和到期时间。
- **来源与纠正**：每条记忆能展开来源引文；纠正时会生成新记忆并保留旧版本，不会直接篡改历史。
- **隐藏/恢复**：隐藏后不再被召回，但原始对话不会删除；恢复后重新参与。
- **记忆池**：主人私聊的记忆和群成员记忆分池保存；群内还可以按来源群筛选。
- **生命周期**：不同类型有不同保留期；长期不用的记忆会衰减/过期，但正文和来源仍保留，不物理删除。可以手动"运行维护"。
- **立即提炼**：不必等下一轮聊天，可以手动让后台处理最近一批历史事件。

> **怎么让她记住？** 直接说"记住：我习惯用 Asia/Shanghai 时区"这类明确请求，系统会优先写入；普通聊天由后台自动提炼，不保证每句都变成长期记忆。

7. 语音与实时通话

7.1 语音回复

「模型与语音」里可以设置语音开关、概率、音色和试听。当前使用本地 Breeze TTS 的 yuwan 克隆音色。语音回复与文字并存：文字始终保留，语音是额外气泡；语音失败不影响文字。

QQ 私聊/群聊也支持语音：收到语音消息时，通过 SnowLuma 转写成文字，并带「[语音转文字]」标记进入对话；回复语音时会等待本轮后台合成，最长约 120 秒，失败则回退文字。

7.2 实时通话

聊天输入栏旁的「通话」按钮进入实时语音通话：麦克风 → 本地 ASR → 对话 → 流式 TTS 播放。支持自然打断（插话）；通话期间不会同时发送主动消息。

> 通话依赖 ASR（8139）和 TTS（8137）服务。如果按钮不可用或提示未配置，先看「模型与语音」和本机服务状态。

8. 图片、表情包与 Agent 工具

8.1 图片

支持 PNG/JPEG/WebP/GIF，最多 4 张，可纯图片发送。图片会先被识图模型观察；历史、归档和重新打开都能看到原图。

8.2 表情包

表情包库支持上传、自动标签、改名、隐藏/恢复、删除。她可以根据上下文挑一张发出来；普通聊天里概率较低，避免每轮都发表情；你明确要表情包时概率更高。删除表情包不会删除已经发过的聊天图片。

8.3 Agent 能力

「Agent 能力」页可以按需开启：

- 记忆查询：从当前场景允许的记忆池里检索；
- 联网搜索：搜索摘要与来源链接，不会把搜索结果当指令；
- 表情包查询/发送；
- 文件读取/写入、命令执行（仅桌面私聊，默认受审批和目录限制；群聊强制关闭）；
- 工具调用次数、时间、结果大小和预算上限。

> **权限提醒：**群聊永远不继承主人的本地文件/命令权限。命令执行可能修改文件或联网；逐次批准模式下每次都要你确认。拒绝后她应停止该操作，不应反复索要批准。

工具过程只在日志里显示，不会把思考或工具 JSON 塞进聊天正文；日志的「原始日志」可以看到细节。

9. 主动消息与独处思考

主动行为分两种，设置页里可以分别调整；总开关仍是「主动消息」。

长时间没聊天

沉默达到设定空闲时间、且今天没超上限、不在安静时段，她可以主动发一条短消息。原设置的空闲/间隔/每日上限继续生效。

回复后独处

你回复完后约 150 秒没继续，她会先自己想一想（有限轮/步），再决定主动开口还是保持安静。默认最多 2 轮、4 步、每天 6 次。

- 你在这段时间里发了新消息、按了停止、归档/删除会话，待执行的独处思考会取消。
- 安静时段（默认 23:00–08:00）和每日上限对所有主动消息生效，避免半夜打扰或刷屏。
- 独处时可以按开关使用只读工具（记忆/表情包/联网）和选择语音/表情；群聊目标受群权限限制。
- 不想被打扰：关闭总开关，或把"回复后独处"关掉；也可以随时在 QQ 里发停止。

10. 模型、设置与外观

10.1 模型与语音

按能力卡配置：计划/对话模型、识图、语音转文字、文字转语音、嵌入、重排序。对话、识图、本地 Breeze 语音是当前主要可用能力；其余若未接入，页面会明确标注“待接入”，不要把它们当成已验收功能。

密钥只保存在服务端（`data/secrets.json`），页面只显示脱敏状态；保存后热加载，不需要重启。未配置对话模型时发送消息会明确提示，不会编造回答。

10.2 上下文预算

默认总上下文约 48 KB、单条输入约 12 KB。人格档案和输入分别计入预算；超限会给出可操作提示，不会假装是模型故障。

10.3 外观与账户

浅色、深色、跟随系统三种主题；桌面端和手机端都有响应式布局。侧栏底部会显示本机状态。主题和部分界面偏好会保存在浏览器本地；聊天内容不写 localStorage。

10.4 QQ 与主动消息设置

QQ 设置包括主人/机器人 QQ、反向 WS 地址、令牌、私聊/群聊开关、群白名单、接话模式、防抖与发送节奏。主动消息设置包括长空闲参数、回复后独处参数、安静时段、每日上限、QQ 追话/工具/媒体开关和一个独处工具调用预算。

11. 归档、备份、隐私与安全

11.1 归档与删除

- 归档：旧对话变只读，保留可回看；恢复会把当前对话归档，确保同时只有一段活动对话。
- 永久删除：会写入独立删除账本，清除该对话的事件、请求/生成、附件引用及由它产生的记忆来源，无法恢复。
- 删除事件/消息会同时处理派生输出和未共享媒体；共享素材可被其他消息保留。

11.2 导出与恢复

项目根目录下可执行（示例）：

```
.\app\.venv\Scripts\python.exe -m agi_wind.cli archive export --output data\exports\manual.zip
.\app\.venv\Scripts\python.exe -m agi_wind.cli archive verify data\exports\manual.zip
.\app\.venv\Scripts\python.exe -m agi_wind.cli archive import data\exports\manual.zip --mode clone --lat
est-ledger data\governance
```

导出包用于迁移对话/人格/记忆等公开档案；它不包含 API 密钥、QQ 令牌、完整数据库或语音参考文件。恢复默认用新的命名空间和删除账本，不能拿旧备份覆盖新的删除记录。

11.3 哪些文件绝不能发出去

`data/local-db.json`、`data/access-token.txt`、`data/secrets.json`、`data/settings.json` 以及 QQ/模型令牌都属于秘密或本机配置；不要把 `data` 目录整体发到群里或公开仓库。

文件说明：`data/assets` 是媒体，`data/dev-postgres` 是数据库目录，运行中直接复制不等于有效备份；要按官方导出/备份流程做。

11.4 安全

本机回环访问自动登录；对外访问请使用 HTTPS（Caddy 已在本机运行）并更换默认客户端密钥。公开网络不要直接暴露 18440/55432/5099。QQ 连接令牌只给 SnowLuma，不写进浏览器存储。

12. 常见问题与排查

现象	优先检查	处理
网页打不开	Gateway 是否运行	运行 `查看本地状态.cmd`；必要时重启本地服务
能打开网页但发消息报模型未配置	「模型与语音 → 计划/对话」	填供应商、Base URL、模型 ID、API Key，保存后重试
QQ 显示未连接	SnowLuma 是否登录、WS 地址、令牌	打开 5099 完成登录；核对连接令牌和反向 WS 地址
QQ 回复太慢	防抖等待、发送节奏设置	调小"说完后等待/最多等到/基础等待"；但不要调成 0 长期使用
QQ 回复太快、碎片消息多	基础等待、最少间隔、每轮最多段数	把基础等待调到 1.2–1.5，最少间隔调到 2–3，最多段数调到 4–6
她没回我	是否在生成、QQ 是否在线、静音时段	看连接页状态；发 `/stop` 后重发；检查主动消息安静时段
语音没有声音	语音开关、Breeze 服务、音色	看「模型与语音 → 文字转语音」状态，试听；检查 8137
通话按钮不可用	ASR/TTS 服务、浏览器麦克风权限	检查 8139/8137，允许浏览器使用麦克风
日志看不懂	「她的活动」简单视图	默认只看卡片；需要细节再点"看原始日志"
记忆里出现了不想保留的内容	记忆页状态与来源	隐藏；或从源对话删除；不要直接改数据库
群聊不回复	群是否在允许列表、接话模式	在连接页启用该群；智能接话需要明确追问或 @/引用

排查顺序：先看连接页/状态页，再看聊天页日志的"她的活动"，最后才切"看原始日志"。大多数问题在状态和日志里已有明确原因码。

13. 当前边界

- **QQ 防抖只覆盖主人私聊纯文字**；群聊不聚合，图片/语音/命令不进入文字批次，避免顺序和权限问题。
- **防抖批次是内存态**：Gateway 崩溃/重启会丢失尚未提交的少量碎片；这不会影响已经落盘的历史。
- **真实环境验收**：QQ 连接依赖 SnowLuma 登录和网络；大体量群聊、不同 QQ 客户端版本、真实麦克风/扬声器等仍以实际使用为准。
- **部分能力待接入**：嵌入/重排序等模型角色、Live2D、NAS 部署等尚未作为完整验收项；页面标注"待接入"的不要当作可用。
- **主动消息与独处**：受安静时段、每日上限、工具权限和 QQ 目标绑定约束；不是无限自主动作。

> **最后记住三件事：**
> 1）聊天、语音、QQ 都是增强项，文字和档案是核心；
> 2）让她慢一点、像人一点，可以调 QQ 的"防抖 + 发送节奏"，不用改代码；
> 3）遇到异常先看状态页和"她的活动"，需要细节再开原始日志。